

Linearní regrese

Mate k dispozici fragment z výstupu lineární regrese:

Dependent

Regression Equation Section

Independent Variable	Regression Coefficient b(i)	Standard Error Sb(i)
Intercept	2,6461	0,6080
x1	0,0921	0,0109
x2	-0,0604	0,0145
x3	-0,0581	0,0105

Analysis of Variance Section

Source	DF	Sum Of Squares	Mean Square
Model	3	134,7	44,9
Error	30	15,3	0,51

a. Napiste tvar regresního modelu

$$\hat{y} = 2,6461 + 0.0921 \cdot x_1 - 0.0604 \cdot x_2 - 0.0581 \cdot x_3$$

b. Jaky byl rozsah vyberu (kolik radku v datove matici)?

$$n - k - 1 = \text{Error}$$

$$n = \text{Error} + k + 1 = \text{Error} + \text{pocet promennych} + 1$$

$$n = 30 + 3 + 1 = 34$$

c. Lze zamítnout hypotézu, že regresní koeficienty jsou nulové?

t-statistika:

$$t_0 = \left| \frac{b_0}{Sb_0} \right| = \left| \frac{2.6461}{0.6080} \right| = 3.72$$

$$t_1 = \left| \frac{b_1}{Sb_1} \right| = \left| \frac{0.0921}{0.0109} \right| = 8.45$$

$$t_2 = \left| \frac{b_2}{Sb_2} \right| = \left| \frac{-0.0604}{0.0145} \right| = 4.17$$

$$t_3 = \left| \frac{b_3}{Sb_3} \right| = \left| \frac{-0.0581}{0.0105} \right| = 5.53$$

kritická hodnota z tabulek pro $df = 30$ a $\alpha = 0.05$ je 2.042

hypotézu o nulovosti koeficientu lze zamítnout

d. Spocitejte koeficient determinace

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{RSS}{MSS + RSS} = 1 - \frac{15.3}{134.7 + 15.3} = 0.88$$

e. Odhadnete rozptyl nahodne slozky modelu

$$s^2 = \frac{RSS}{n - k - 1} = \frac{15.3}{30} = 0.51$$

d. Je model uspokojivy pro vysvetleni zavislosti Y na regresorech?

F-statistika:

$$f_{krit} = 2.92$$

$$F = \frac{MMS}{RMS} = \frac{44.9}{0.51} = 88$$

$F \gg f \implies$ model je statisticky vyznamny

Logisticka regrese

V logistickem regresnim modelu vyjadrujicim zavislost poskozeni sdravi (velicina POSKOZENI ma hodnotu 0, 1) na pobytu v rizikovem prostredi (velicina RIZIKO ma hodnoty 0, 1) a na intenzite rehabilitace (velicina REHAB, spojita s kladnymi hodnotami) ma nasledujici vysledky:

Independent Variable	Regression Coefficient b(i)	Standard Error Sb(i)	p
Intercept	4.175	1.883	0.02662
rehab	-0.365	0.125	0.00357
riziko	1.713	0.764	0.02494

a. Napiste tvar regresniho modelu

pro $\alpha = 0.05$:

$$\ln\left(\frac{p}{1-p}\right) = 4.175 - 0.365 \cdot rehab + 1.713 \cdot riziko$$

b. Meni se pravdepodobnost poskozeni zdravi intenzitou rehabilitace? Pokud ano, tak jak?

pavdepodobnost klesa, protoze koeficient je zaporny

c. Urcete 95%ni interval spoehlivosti pro pomer sancí(odds ratio) poskození zdraví vystavením riziku. Interpretujte tento výsledek.

Bodový odhad pro kouření ($\beta = 1.713$):

$$OR = e^{\beta} = e^{1.713} = 5.546$$

Interval spoehlivosti:

$$meze = \beta \pm z_{\alpha/2} \times S_i = 1.713 \pm (1.96 \times 0.764)$$

$$meze = [0.2156, 3.2104]$$

transformace na OR:

$$OR_{dolní} = e^{0.2156} = 1.241$$

$$OR_{horní} = e^{3.2104} = 24.789$$

Výsledek:

$$95\%IS = (1.241; 24.789)$$

Interpretace:

- interval neobsahuje 1, takže můžeme považovat faktor za významný pozitivní efekt na sanci výskytu události
- skutečná hodnota OR leží s 95% jistotou v tomto intervalu, faktor zvyšuje sanci minimálně 1,24x a maximálně 24,79x
- interval je široký, možná málo dat?

d. Napíšte klasifikační pravidlo umožňující podle hodnot roky a kouření klasifikovat osoby do kategorie nemocný/zdravý

$$p = \frac{1}{1 + e^{-x^T \beta}} = \frac{1}{1 + e^{-1(4.175 - 0.365 \cdot \text{rehab} + 1.731 \cdot \text{riziko})}}$$

pokud $p \geq c$ klasifikujeme jako NEMOCNÝ

PCA

Vyberova korelační matice má následující vlastní čísla

No.	Eigenvalue
1	6.097632
2	1.225727
3	0.246754

No.	Eigenvalue
4	0.161526
5	0.102103
6	0.097033
7	0.056346
8	0.012879

Co z toho muzete ususzovat? Jaky rozmer ma korelacni matice a jaky je spravny rozmer matice dat?

korelacni matice ma rozmer 8×8

matice dat ma rozmer $n \times 8$

kde je $\lambda \approx 0$ tam je temer linearni zavislost

pokud vicekrat \Rightarrow multikolinearita

efektivni dimenze = 2, prvni dve komponenty

$$K = \frac{\lambda_{max}}{\lambda_{min}} = \frac{6.097632}{0.012879} = 473$$

$K > 100 \Rightarrow$ multikolinearity

Jakou cast celkoveho rozptylu vysvetluji prvni dve hlavni komponenty?

$$\frac{6.097632 + 1.225727}{8} = \frac{7.323359}{8} = 0.915 = 91.5\%$$

Diskriminacni analyza

Z nasledujiciho vystupu zformulujte klasifikacni pravidlo a vypoctete procento spravne klasifikace. Napiste predpoklady potrebne pro vyuziti linearni diskriminacni funkce.

Linear Discriminant
Functions

	skup	
Variable	1	2
Constant		
Constant	-22.840	-47.031
x1	2.575	3.638
x3	1.151	1.711

Classification Count Table for skup

	Predicted		
Actual	0	1	Total
0	23	1	24
1	1	25	26
Total	24	26	50

Klasifikacni pravidlo

$$LDF_1 = -22.840 + 2.575 \times x_1 + 1.151 \times x_3$$

$$LDF_2 = -47.031 + 3.638 \times x_1 + 1.711 \times x_3$$

$$LDF_1 > LDF_2 \implies \textit{skupina1}$$

$$LDF_2 > LDF_1 \implies \textit{skupina2}$$

$$LDF_1 = LDF_2 \implies \textit{nahodne}$$

Nebo jednoduseji pro dve skupiny:

$$(-22.840 - (-47.031)) + x_1 \times (2.575 - 3.638) + x_3 \times (1.151 - 1.711) > 0 \implies \textit{skupina1}$$

Procento spravne klasifikace

$$\frac{\textit{spravne}}{\textit{celkem}} = \frac{23 + 25}{50} = 0.96 = 96\%$$

Podminky pro vyuziti LDF:

nahodny vektor ma normalni rozdeleni a skupiny se lisi jen vektorem strednich hodnot

Matice

$$a = [1, 1, 1]^T$$

$$x = [x_1, x_2, x_3]^T$$

$$B = \begin{bmatrix} 1 & -2 & 3 \\ -2 & 3 & 3 \\ 3 & 3 & 2 \end{bmatrix}$$

a. $a^T x$

$$a^T x = [1 \quad 1 \quad 1] \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = x_1 + x_2 + x_3$$

b. ax^T

$$ax^T = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & x_3 \\ x_1 & x_2 & x_3 \\ x_1 & x_2 & x_3 \end{bmatrix}$$

c. Ba

$$Ba = \begin{bmatrix} 1 & -2 & 3 \\ -2 & 3 & 3 \\ 3 & 3 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix}$$

Matice

$$a = [1, 1, 1]^T$$

$$B = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix}$$

c. Ba

$$Ba = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ 2 \\ 6 \end{bmatrix}$$

Predpoklady klasického lineárního modelu:

- střední hodnota náhodné složky nulová
- náhodné složky jsou nekorelované
- matice dat X je nenahodná matice
- sloupce matice jsou lineárně nezávislé, tedy $h(X) = k + 1 \leq n$

Zapíšte maticové lineární regresní model

$$y = X\beta + \epsilon$$

y : $n \times 1$

ϵ : $n \times 1$

X : $n \times (k + 1)$

β : $(k + 1) \times 1$

Projekční matice:

$$H = X(X^T X)^{-1} X^T$$

$$\hat{y} = Hy$$

promítá y do roviny dané regresory

H : $n \times n$

co znamenají hodnoty diagonálních prvků:

Jak velký vliv má dané pozorování na regresní model

Rozsah: $0 \leq h_{ii} \leq 1$

Součet diagonálních prvků $\sum h_{ii} = k + 1$